

1-р гишүүн: Өгөгдлийн инженерчлэл ба Хайн судлах шинжилгээ

Төслийн нэр: Улаанбаатар хотын агаарын бохирдлын таамаглал

Гишүүн: [Нэр]

Хариуцсан хэсэг: Өгөгдлийн инженер & EDA

Хариуцах ажлуудын жагсаалт

1. Өгөгдлийн эх сурвалжийг олж тогтоох, татаж авах
2. Өгөгдөл цэвэрлэх (дутуу утга, давхардал, алдаа арилгах)
3. Хайн судлах шинжилгээ (EDA): графикууд, гистограмм, scatter plot
4. Хувьсагчдын хоорондох корреляцийн матриц
5. Категори хувьсагчдыг кодлох
6. Train/test хуваах

1. Өгөгдлийн эх сурвалж ба татаж авах

Бид хоёр эх сурвалжаас өгөгдөл цуглуулсан.

Өгөгдөл	Эх сурвалж	API
Цаг агаар (температур, чийгшил, салхи, хур, даралт)	Open-Meteo Historical Weather	archive-api.open-meteo.com
PM2.5 агаарын бохирдол	Open-Meteo Air Quality	air-quality-api.open-meteo.com

Байршил: Улаанбаатар хот (47.91°N, 106.88°E)

Хугацаа: 2021-05-07 – 2026-05-06 (сүүлийн 5 жил, цагийн нягтаршилтай)

Өгөгдөл аль хэдийн татагдсан байна. Шууд ачаалж байна...

2. Өгөгдөл ачаалах ба анхны үзлэг

```
=== Өгөгдлийн ерөнхий мэдээлэл ===
Хэмжээ:      43,824 мөр × 7 багана
Хугацаа:      2021-05-07 - 2026-05-06
Баранууд:     ['time', 'temperature_2m', 'relative_humidity_2m', 'wind_speed_10m', 'precipitation',
'surface_pressure', 'pm2_5']
```

	time	temperature_2m	relative_humidity_2m	wind_speed_10m	precipitation	surface_pressure	pm2_5
0	2021-05-07 00:00:00	3.3	35	7.6	0.0	865.6	NaN
1	2021-05-07 01:00:00	-0.0	47	10.4	0.0	863.8	NaN
2	2021-05-07 02:00:00	1.0	44	7.9	0.0	863.8	NaN
3	2021-05-07 03:00:00	1.4	45	7.1	0.0	863.4	NaN
4	2021-05-07 04:00:00	-0.0	53	7.6	0.0	862.0	NaN
5	2021-05-07 05:00:00	0.2	54	6.9	0.0	861.4	NaN
6	2021-05-07 06:00:00	1.6	52	6.2	0.0	861.7	NaN
7	2021-05-07 07:00:00	4.0	48	9.5	0.0	862.6	NaN

```

=== Өгөгдлийн төрөл ===
time                datetime64[us]
temperature_2m      float64
relative_humidity_2m  int64
wind_speed_10m      float64
precipitation        float64
surface_pressure     float64
pm2_5                float64
dtype: object

=== Хоосон утгын тоо ===

```

	Хоосон тоо	Хувь (%)
time	0	0.0
temperature_2m	0	0.0
relative_humidity_2m	0	0.0
wind_speed_10m	0	0.0
precipitation	0	0.0
surface_pressure	0	0.0
pm2_5	10904	24.9

3. Өгөгдөл цэвэрлэх

Цэвэрлэлтийг дараах дарааллаар хийнэ:

Алхам	Шалтгаан
PM2.5 хоосон мөр хасах	Загварт зорилтот хувьсагч байх ёстой
PM2.5 < 0 хасах	Физикийн хувьд боломжгүй утга
PM2.5 > Q3 + 3×IQR хасах	Хэмжилтийн алдаат хэт их утга
Салхи > $\mu + 3\sigma$ хасах	Хэмжилтийн алдаат хэт их утга
Хур тунадас > $\mu + 3\sigma$ хасах	Хэмжилтийн алдаат хэт их утга

```

=== Цэвэрлэлтийн тайлан ===
Анхны мөр:      43,824
  Хассан (PM2.5 хоосон):  10,904
  Хассан (PM2.5 < 0):      0
  Хассан (PM2.5 > 84.6 (Q3+3IQR)):  1,105
  Хассан (Салхи > 23.2 (3σ)):    371
  Хассан (Хур > 0.88 (3σ)):    388
Үлдсэн мөр:      31,056
Хасалтын %:      29.1%

```

```

=== Цэвэр өгөгдлийн статистик ===


```

	temperature_2m	relative_humidity_2m	wind_speed_10m	precipitation	surface_pressure	pm2_5
count	31056.00	31056.00	31056.00	31056.00	31056.00	31056.00
mean	0.26	61.13	7.70	0.02	870.13	18.45
std	14.55	20.71	4.69	0.08	6.44	17.83
min	-41.30	9.00	0.00	0.00	840.80	0.10
25%	-12.00	46.00	4.30	0.00	866.10	6.20
50%	1.00	63.00	6.80	0.00	870.10	11.80
75%	12.30	78.00	10.10	0.00	874.20	24.10
max	33.90	100.00	23.20	0.80	892.00	84.50

Давхардсан мөр: 0

4. Хайн судлах шинжилгээ (EDA)


4.1 Хувьсагчдын тархалт




4.2 PM2.5 цаг хугацааны хэлбэлзэл (Time Series)



4.3 PM2.5-ийн улирлын хэлбэлзэл




4.4 Scatter plot — PM2.5 ба оролтын хувьсагчид



5. Корреляцийн матриц

=== Корреляцийн матриц ===

	temperature_2m	relative_humidity_2m	wind_speed_10m	precipitation	surface_pressure
pm2_5					
temperature_2m	1.00	-0.38	0.27	0.10	-0.23
-0.56					
relative_humidity_2m	-0.38	1.00	-0.32	0.15	0.00
0.27					
wind_speed_10m	0.27	-0.32	1.00	0.15	-0.10
-0.47					
precipitation	0.10	0.15	0.15	1.00	-0.11
-0.11					
surface_pressure	-0.23	0.00	-0.10	-0.11	1.00
0.02					
pm2_5	-0.56	0.27	-0.47	-0.11	0.02
1.00					



```
PM2.5-тай корреляц (нэмэлт оролт хасч):  
temperature_2m      : 0.560  
wind_speed_10m      : 0.470  
relative_humidity_2m : 0.270  
precipitation        : 0.110  
surface_pressure     : 0.020
```

6. Категори хувьсагч кодлох

Цаг агаарын өгөгдөл тоон хувьсагчтай. Гэхдээ **сар** (month) болон **халаалтын улирал** (heating_season) хувьсагчдыг нэмж, категорируулан кодлоно.

```
Улирлын тархалт:  
season  
Намар      8546  
Хавар      7902  
Өвөл       7638  
Зун        6970  
  
One-Hot Encoding нэмсний дараах баганууд:  
['season', 'season_Намар', 'season_Хавар', 'season_Өвөл']
```

```
heating_season утгууд:  
heating_season  
Бусад      17723  
Халаалтын улирал 13333  
  
Нэмэгдсэн хувьсагчид:  
   heating_season  season_Өвөл  season_Хавар  temp_x_wind  
0                0            0            0          165.88  
1                0            0            0          217.10  
2                0            0            0          248.81  
3                0            0            0          303.80  
4                0            0            0          343.20
```

7. Train / Test хуваах

```
=== Train / Test хуваалт ===  
Нийт өгөгдөл:      31,056  
Сургалтын өгөгдөл: 24,844 (80%)  
Туршилтын өгөгдөл:  6,212 (20%)  
  
PM2.5 дундаж:  
Train: 18.37 µg/m³  
Test:  18.75 µg/m³
```

```
Хадгалагдлаа:  
train.csv → 24844 мөр  
test.csv  → 6212 мөр
```

8. Дүгнэлт

Алхам	Үр дүн
Нийт цуглуулсан өгөгдөл	43,824 цагийн бичлэг
Цэвэрлэсний дараа	~31,056 бичлэг (29.1% хасагдсан)
PM2.5 дундаж (цэвэрлэсний дараа)	~17–19 $\mu\text{g}/\text{m}^3$
Хамгийн их корреляц PM2.5-тай	Температур (-), Халаалтын улирал (+)
Нэмэлт хувьсагч	month, hour, heating_season, temp_x_wind, season_*
Сургалтын өгөгдөл	80% (~24,844 мөр)
Туршилтын өгөгдөл	20% (~6,212 мөр)