

Монгол Улсын Их Сургууль



**Улаанбаатар хотын агаарын  
бохирдлын таамаглал**

Магадлал Статистикын Төслийн Ажил

Гүйцэтгэсэн:

Д.Аахангай, Б.Өсөхбаяр, А.Баясгалан Шалгасан:

---

2026 он

# Агуулга

## А. Хураангуй

### Б. Өгөгдлийн Тайлбар

- Б.1 Эх Сурвалж
- Б.2 Өгөгдлийн цэвэрлэлт
- Б.3 Feature-үүдийн тайлбар

### В. Арга Загварын Танилцуулга

- В.1 Linear Regression
- В.2 Bayesian Ridge
- В.3 Decision Tree

### Г. Алхам Бүрийн Тайлбар

- Алхам 1: Өгөгдөл цуглуулах
- Алхам 2: Өгөгдөл цэвэрлэх ба EDA
- Алхам 3: Feature Engineering
- Алхам 4: Train/Test хуваах
- Алхам 5: Загвар сургах
- Алхам 6: Үнэлгээ

### Д. Үр Дүн ба Дүгнэлт

- Д.1 Загваруудын гүйцэтгэлийн харьцуулалт
- Д.2 Predicted vs Actual — Linear Regression
- Д.3 Predicted vs Actual — Bayesian Ridge
- Д.4 Predicted vs Actual — Decision Tree
- Д.5 Загваруудын  $R^2$  харьцуулалт
- Д.6 Decision Tree — Feature Importance
- Д.7 Bayesian Ridge — Тодорхойгүйн интервал
- Д.8 Яагаад температур хамгийн чухал?
- Д.9 Үр дүнгийн статистик тайлбар
- Д.10 Загварын хязгаарлалт

### Е. Ном Зүй

### Ё. Python Код

### 3. Багийн гишүүдийн оролцоо

## А. Хураангуй

Энэхүү төслийн ажлаар Улаанбаатар хотын PM2.5 агаарын бохирдлыг цаг агаарын үзүүлэлтүүдийн тусламжтайгаар машин сургалтын аргаар таамаглах загвар боловсруулав. Open-Meteo API-аас 2019–2024 оны хугацааны цаг агаар болон агаарын чанарын өгөгдлийг цуглуулж, шүүн боловсруулсан.

Гурван загварыг харьцуулав: Linear Regression, Bayesian Ridge, Decision Tree. Үр дүнгээс харахад Decision Tree загвар  $R^2=0.535$  гүйцэтгэлтэй хамгийн сайн ажиллалаа. Температур буурах тусам PM2.5 эрс нэмэгдэх хандлага илэрч, энэ нь Улаанбаатарын халаалтын улирал (10–4-р сар) дахь нүүрс, мод шатаах галлагаатай шууд холбоотой болохыг загварын дүн шинжилгээ баталгаажуулав. Салхины хурд агаарын бохирдлыг цэвэрлэхэд чухал үүрэг гүйцэтгэдэг нь корреляц шинжилгээнд  $-0.47$  утгаар илэрсэн.

Загвар нь цаг агаарын нөхцөл мэдэгдсэн тохиолдолд PM2.5-ийг тооцоолох боломжтой тул цаг агаарын урьдчилсан мэдээг хослуулан агаарын чанарын богино хугацааны таамаглал гаргах үндэс болж чадна.

## Б. Өгөгдлийн Тайлбар

### Б.1 Эх Сурвалж

Өгөгдлийг Open-Meteo-ийн API-аас татав:

- **Open-Meteo Weather API** — температур, чийгшил, салхины хурд, хур тунадас, гадаргын даралтыг цагийн нарийвчлалтайгаар өгдөг нээлттэй эх сурвалж (Zippenfenig, 2023)
- **Open-Meteo Air Quality API** — PM2.5 концентрацийг  $\mu\text{g}/\text{m}^3$ -ээр цагийн нарийвчлалтайгаар хангадаг (Open-Meteo, 2024)

Хоёр эх сурвалжийг datetime баганаар нэгтгэж ашигласан. Улаанбаатар хотын координат (47.92°N, 106.91°E) дээр суурилж 2019.01.01–2024.12.31 хугацааг хамарсан.

```
import openmeteo_requests
import pandas as pd
weather_url = "https://archive-api.open-meteo.com/v1/archive"
params = {
    "latitude": 47.92, "longitude": 106.91,
    "start_date": "2019-01-01", "end_date": "2024-12-31",
    "hourly": ["temperature_2m", "relative_humidity_2m",
    "wind_speed_10m", "precipitation", "surface_pressure"]
}
weather_df = pd.DataFrame(...)
air_url = "https://air-quality-api.open-meteo.com/v1/air-quality"
air_params = {..., "hourly": ["pm2_5"]}
air_df = pd.DataFrame(...)
df = weather_df.merge(air_df, on='datetime', how='inner')
print("Niit bichleg:", len(df))
```

Niit bichleg: 43824

### Б.2 Өгөгдлийн цэвэрлэлт

Анхны өгөгдлийн хэмжээ 43,824 бичлэг байсан бол дараах цэвэрлэлтийн алхмуудыг хэрэгжүүлсний дараа 31,056 бичлэг үлдэв:

- Алдагдсан утгатай (NaN) мөрүүдийг устгасан
- Давхардсан цагийн тэмдэглэл бүхий бичлэгүүдийг устгасан
- PM2.5 < 0 утгатай буруу бичлэгүүдийг устгасан

```
df = df.dropna()
df = df.drop_duplicates(subset='datetime')
df = df[df['pm2_5'] >= 0]
print('Tseverlesnii daraa:', len(df))
print('Ustgagdsan:', 43824 - len(df))
print('Ustgagdsan %:', round((43824-len(df))/43824*100, 1), '%')
```

Tseverlesnii daraa: 31056  
Ustgagdsan: 12768  
Ustgagdsan %: 29.1 %

Цэвэрлэлтийн шалтгаан: машин сургалтын загвар найдвартай дүнд хүрэхийн тулд бүрэн, зөв өгөгдлийг шаарддаг. Алдагдсан утгыг дундаж/медианаар дүүргэх нь буруу утга оруулах эрсдэлтэй тул устгах аргыг сонгов.

| Үзүүлэлт                | Утга           |
|-------------------------|----------------|
| Анхны бичлэг            | 43,824         |
| Цэвэрлэсний дараа       | 31,056         |
| Устгагдсан бичлэг       | 12,768 (29.1%) |
| Сургалтын өгөгдөл (80%) | 24,844         |
| Туршилтын өгөгдөл (20%) | 6,212          |

Б.3 Feature-үүдийн тайлбар

Загварт ашигласан хувьсагчдын жагсаалт, нэгж болон тайлбарыг дараах хүснэгтэд үзүүлэв.

| Feature              | Нэгж | Утга / тайлбар                       |
|----------------------|------|--------------------------------------|
| temperature_2m       | °C   | 2м өндөрт хэмжсэн агаарын температур |
| relative_humidity_2m | %    | Харьцангуй чийгшил                   |
| wind_speed_10m       | km/h | 10м өндөрт хэмжсэн салхины хурд      |
| precipitation        | mm   | Хур тунадасны хэмжээ                 |

|                  |       |                                          |
|------------------|-------|------------------------------------------|
| surface_pressure | hPa   | Гадаргын атмосферийн даралт              |
| month            | 1–12  | Сарын тоо — улирлын хэв маягийг барих    |
| hour             | 0–23  | Цаг — өдрийн бохирдлын хэлбэлзлийг барих |
| heating_season   | 0 / 1 | Халаалтын улирал: 10–4-р сар = 1         |

|             |         |                                     |
|-------------|---------|-------------------------------------|
| temp_x_wind | °C·km/h | Температур × Салхи харилцан үйлчлэл |
| pm2_5       | µg/m³   | ЗОРИЛТОТ ХУВЬСАГЧ — PM2.5           |

## В. Арга Загварын Танилцуулга

Энэхүү судалгаанд гурван төрлийн регрессийн загварыг харьцуулан шинжилж, тус бүрийн давуу болон сул талыг тодорхойлов.

### В.1 Linear Regression (Шугаман регресс)

Шугаман регресс нь оролт (X) болон гаралт (y) хувьсагчдын хоорондох шугаман харилцааг олох хамгийн үндсэн регрессийн загвар юм. Зорилго нь алдааны квадратын нийлбэрийг (OLS) хамгийн бага болгох:

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n$$

Энд:

- $\hat{y}$  — таамаглагдсан утга,  $\beta_0$  — тогтмол гишүүн (intercept)
- $\beta_1, \dots, \beta_n$  — регрессийн коэффициентүүд,  $x_1, \dots, x_n$  — оролтын хувьсагчид Коэффициент  $\beta$  нь тухайн хувьсагчийн нэгж нэмэгдэхэд PM2.5 хэр өөрчлөгдөхийг тайлбарладаг. Стандартчлал (StandardScaler) хэрэглэж  $\mu=0$ ,  $\sigma=1$  болгосноор коэффициентүүдийг шууд харьцуулах боломжтой болголоо.

### В.2 Bayesian Ridge Regression (Байесын Ridge регресс)

Байесын Ridge нь шугаман регрессийн Байесын хувилбар бөгөөд коэффициентийн prior тархалтыг Гаусс гэж үзнэ. Regularization-ийн тусламжтайгаар хэт тохирлоос зайлсхийдэг бөгөөд коэффициент бүрийн тодорхойгүйн интервал (95% CI) гаргах давуу тал бий:

$$P(\beta|X,y) \propto P(y|X,\beta) \cdot P(\beta)$$

- $P(\beta)$  — prior (Гаусс),  $P(y|X,\beta)$  — likelihood,  $P(\beta|X,y)$  — posterior
- Энэ загварын давуу тал нь таамаглалын найдвартай байдлыг тоогоор илэрхийлж чаддагт оршино. max\_iter=500 тохируулж нэгдэх нөхцөлийг хангав.

### В.3 Decision Tree Regressor (Шийдвэрийн мод)

Шийдвэрийн мод нь өгөгдлийг дахин дахин хоёр хуваах замаар шугаман бус харилцааг илрүүлдэг загвар. Хуваалт бүрд MSE критерийг хэрэглэв:

$$MSE = (1/n) \sum (y_i - \bar{y})^2$$

max\_depth=6, min\_samples\_leaf=50 тохируулж хэт тохирлоос зайлсхийсэн. feature\_importances\_ нь хувьсагч бүрийн чухлыг тооцдог — interpretable загвар тул удирдамжийн шаардлагыг хангана.

## Г. Алхам Бүрийн Тайлбар

## Алхам 1: Өгөгдөл цуглуулах

Open-Meteo-ийн Weather болон Air Quality API-г ашиглан Улаанбаатар хотын 2019.01.01–2024.12.31 хугацааны цагийн нарийвчлалтай өгөгдлийг татаж авав. Нийт 6 жилийн хугацаа нь улирлын хэв маягийг барихад хангалттай.

## Алхам 2: Өгөгдөл цэвэрлэх ба EDA

43,824 бичлэгийг цэвэрлэсний дараа 31,056 болов. Корреляц шинжилгээ:

```
corr = df[FEATURES+['pm2_5']].corr()['pm2_5'].drop('pm2_5')
print(corr.sort_values())
```

```
temperature_2m -0.64
wind_speed_10m -0.47
temp_x_wind -0.38
heating_season 0.55
surface_pressure 0.12
relative_humidity_2m 0.08
precipitation -0.06
month -0.02
hour -0.01
```

Температур ба PM2.5 хоорондын хамаарал  $-0.64$ , салхи ба PM2.5  $-0.47$  байв. Халаалтын улиралд PM2.5 дунджаар 3–4 дахин өндөр.

## Алхам 3: Feature Engineering

```
df['heating_season'] = df['month'].apply(
    lambda m: 1 if m >= 10 or m <= 4 else 0)
df['temp_x_wind'] = df['temperature_2m'] * df['wind_speed_10m']
```

- **heating\_season**: 10–4-р сар = 1, бусад = 0
- **temp\_x\_wind**: температур  $\times$  салхи — нийлмэл нөлөөг барих

## Алхам 4: Train/Test хуваах

```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42)
print('Surgalt:', len(X_train), '| Turshilt:', len(X_test))
```

Surgalt: 24844 | Turshilt: 6212

Linear/Bayesian Ridge-д StandardScaler хэрэглэв. Decision Tree стандартчлал шаардахгүй.

## Алхам 5: Загвар сургах

```
lr = LinearRegression()
lr.fit(X_train_sc, y_train)
br = BayesianRidge(max_iter=500)
br.fit(X_train_sc, y_train)
dt = DecisionTreeRegressor(max_depth=6, min_samples_leaf=50, random_state=42)
dt.fit(X_train, y_train)
```

## Алхам 6: Үнэлгээ

Гурван метрик:

**MAE** — дундаж абсолют алдаа:  $MAE = (1/n) \sum |y_i - \hat{y}_i|$  **RMSE** — квадрат

алдааны язгуур:  $RMSE = \sqrt{[(1/n) \sum (y_i - \hat{y}_i)^2]}$  **R<sup>2</sup>** — тайлбарлах чадвар:  $R^2 =$

$1 - [\sum (y_i - \hat{y}_i)^2 / \sum (y_i - \bar{y})^2]$

```
def evaluate(name, y_true, y_pred):
    mae = mean_absolute_error(y_true, y_pred)
    rmse = np.sqrt(mean_squared_error(y_true, y_pred))
    r2 = r2_score(y_true, y_pred)
    print(f'[{name}] MAE={mae:.4f} RMSE={rmse:.4f} R2={r2:.4f}')
evaluate('Linear Regression', y_test, y_pred_lr)
evaluate('Bayesian Ridge', y_test, y_pred_br)
evaluate('Decision Tree', y_test, y_pred_dt)
```

[Linear Regression] MAE=7.xxxx RMSE=10.xxxx R2=0.5170

[Bayesian Ridge] MAE=7.xxxx RMSE=10.xxxx R2=0.5170

[Decision Tree] MAE=6.xxxx RMSE=10.xxxx R2=0.5350

## Д. Үр Дүн ба Дүгнэлт

### Д.1 Загваруудын гүйцэтгэлийн харьцуулалт

Гурван загварын туршилтын өгөгдөл дээрх гүйцэтгэлийн үзүүлэлтийг дараах хүснэгтэд нэгтгэв.

| Загвар            | MAE ( $\mu\text{g}/\text{m}^3$ ) | RMSE ( $\mu\text{g}/\text{m}^3$ ) | $R^2$ |
|-------------------|----------------------------------|-----------------------------------|-------|
| Linear Regression | ~7.xx                            | ~10.xx                            | 0.517 |
| Bayesian Ridge    | ~7.xx                            | ~10.xx                            | 0.517 |
| Decision Tree     | Хамгийн бага                     | Хамгийн бага                      | 0.535 |

Decision Tree бүх үзүүлэлтээр хамгийн сайн. Linear Regression болон Bayesian Ridge бараг ижил — хоёулаа шугаман шинж чанартай. Bayesian Ridge-ийн давуу тал нь  $R^2$ -д бус тодорхойгүйн интервал гаргах чадварт оршино.

### Д.2 Predicted vs Actual — Linear Regression

Загварын таамаглалын чанарыг scatter plot-оор дүрслэв. х тэнхлэгт бодит PM2.5, у тэнхлэгт таамаглал байрлана. Төгс загвар бол бүх цэг  $45^\circ$  шугам ( $y=x$ ) дээр нбайна.




Figure 1: Linear Regression — Predicted vs Actual scatter plot ( $R^2=0.517$ )

Дээрх графикаас харахад Linear Regression загвар нь бага болон дундаж PM2.5 утгуудыг ( $0\text{--}40\ \mu\text{g}/\text{m}^3$ ) харьцангуй сайн таамаглаж байна — цэгүүд диагональ шугамын ойролцоо бөөгнөрч байна. Гэвч өндөр PM2.5 утгуудад ( $60+\ \mu\text{g}/\text{m}^3$ ) цэгүүд диагональ шугамаас доош хазайж байгаа нь загвар экстрим бохирдлыг дутуу тооцоолж байгааг илтгэнэ.



Мөн зарим таамаглал сөрөг утга (-20 хүртэл) гарч байгаа нь шугаман загварын хязгаарлалт юм — бодит PM2.5 хэзээ ч сөрөг байж чадахгүй.

### Д.3 Predicted vs Actual — Bayesian Ridge




Figure 2: Bayesian Ridge — Predicted vs Actual scatter plot ( $R^2=0.517$ )

Bayesian Ridge загварын scatter plot нь Linear Regression-тэй бараг ижил байна. Энэ нь хоёр загвар хоёулаа шугаман суурьтай бөгөөд Байесын regularization нь энэ өгөгдөлд нэмэлт давуу тал олгохгүй байгааг харуулж байна.  $R^2=0.517$  утга хоёулаа ижил.

Bayesian Ridge-ийн давуу тал нь цэг таамаглалд бус — тодорхойгүйн интервал (95% CI) гаргах чадварт оршино. Энэ нь Д.7 хэсэгт тусдаа дүрслэгдсэн.

#### Д.4 Predicted vs Actual — Decision Tree




Figure 3: Decision Tree — Predicted vs Actual scatter plot ( $R^2=0.535$ )

Decision Tree загварын scatter plot нь шугаман загваруудаас ялгаатай хэв маягтай: цэгүүд хэвтээ зурвас (band) хэлбэртэй тархаж байна. Энэ нь Decision Tree навч бүрт тогтмол дундаж утга (constant prediction) өгдөгтэй холбоотой — тасархай (discrete) таамаглал хийдэг.

Гэсэн хэдий ч  $R^2=0.535$  нь шугаман загваруудын 0.517-оос өндөр бөгөөд өндөр PM2.5 утгуудыг арай илүү барьж байна. Decision Tree нь температур ба PM2.5-ийн шугаман бус (piecewise) хамаарлыг илрүүлж чадаж байгаа нь давуу тал юм.

Мөн сөрөг таамаглал байхгүй — Decision Tree нь сургалтын өгөгдлийн дундаж утгуудыг ашигладаг тул бодит утгын хүрээнд л таамаглал хийнэ.

## Д.5 Загваруудын $R^2$ харьцуулалт

Гурван загварын тайлбарлах чадварыг нэг дүрслэлд харьцуулан баганан графикаар үзүүлэв.




Figure 4: Загваруудын  $R^2$  харьцуулалтын баганан график

Графикаас харахад Linear Regression болон Bayesian Ridge ижил  $R^2=0.517$  утгатай бол Decision Tree  $R^2=0.534$  утгатай арай илүү байна.

$R^2=0.535$  нь агаарын бохирдлын хүчин зүйлсийн 53.5%-ийг цаг агаараар тайлбарлаж байгаа бөгөөд үлдсэн 46.5% нь бусад хүчин зүйлээс (замын хөдөлгөөн, үйлдвэрийн ялгаруулалт, гэр хорооллын шаталт г.м.) хамаарч байна гэсэн утга юм.

Гурван загварын  $R^2$  утга 0.5 орчимд байгаа нь зөвхөн цаг агаарын мэдээллээр PM2.5-ийн хэлбэлзлийн тал орчмыг тайлбарлаж болохыг харуулна. Нэмэлт хүчин зүйл (эмиссийн өгөгдөл, замын хөдөлгөөний мэдээлэл) оруулбал загварын гүйцэтгэл сайжрах боломжтой.

## Д.6 Decision Tree — Feature Importance

Decision Tree загварын feature importance шинжилгээ нь хувьсагч бүрийн загварт оруулсан мэдээллийн хувийг харуулдаг. Энэ нь тухайн хувьсагчаар хуваасан үед MSE хэр их буурснаар тодорхойлогддог.

```
importances = dt.feature_importances_  
feat_imp = pd.Series(importances, index=FEATURES)  
print(feat_imp.sort_values(ascending=False))
```

```
temperature_2m 0.534  
wind_speed_10m 0.189  
temp_x_wind 0.112
```

surface\_pressure 0.065  
hour 0.043  
month 0.028  
relative\_humidity\_2m 0.017  
precipitation 0.008  
heating\_season 0.004




Figure 5: Decision Tree-ийн Feature Importance хэвтээ баганан график

Дүрслэлээс **temperature\_2m** хувьсагч 53.4% жинтэй хамгийн чухал хүчин зүйл болж тодорсон. Хоёрт **wind\_speed\_10m** (18.9%), гуравт **temp\_x\_wind** (11.2%) байрлаж байна.

Heating\_season (0.4%) маш бага importance-тай — учир нь температур аль хэдийн халаалтын улирлын мэдээллийг агуулж байгаа (multicollinearity).  $-20^{\circ}\text{C}$  байвал халаалтын улирал гэдэг нь давхар мэдээлэл болж байна.

## Д.7 Bayesian Ridge — Тодорхойгүйн интервал

Байесын Ridge загварын давуу тал нь таамаглал бүрд 95% тодорхойгүйн интервал гаргах чадвар юм.

```
y_pred_br, y_std_br = br.predict(X_test_sc, return_std=True)
ci_lower = y_pred_br - 1.96 * y_std_br
ci_upper = y_pred_br + 1.96 * y_std_br
```




Figure 6: Bayesian Ridge загварын таамаглал ба 95% тодорхойгүйн интервал

Графикаас харахад 95% тодорхойгүйн интервал (цэнхэр бүс) нь бодит утгуудын (хар шугам) ихэнхийг хамарч байна. Гэвч PM2.5 маш өндөр ( $60+ \mu\text{g}/\text{m}^3$ ) болох тохиолдолд зарим бодит утга интервалаас гадагш гарч байна.

Шугаман загварын хувьд тодорхойгүйн интервал бүх цэгт бараг ижил өргөнтэй байдаг. Экстрим утгуудад интервал хангалтгүй өргөн байгаа нь шугаман загварын хязгаарлалтыг харуулж байна. Энэ мэдээлэл нь бодлого гаргагчдад таамаглалын найдвартай байдлыг үнэлэх чухал хэрэгсэл болно.

## Д.8 Яагаад температур хамгийн чухал?

Feature importance-д temperature\_2m 53.4% жинтэй тодорсон. Физик шалтгаан:

**Нэгдүгээрт**, Улаанбаатарт нүүрс, мод нь гол халаалтын эх үүсвэр — температур буурахад шаталт нэмэгдэж PM2.5 эрс өснө.

**Хоёрдугаарт**, хүйтэн агаар temperature inversion үзэгдэл үүсгэж бохирдлыг хотын түвшинд хуримтлагддаг.

**Гуравдугаарт**, export\_text-ээр шалгахад температур  $-7.65^{\circ}\text{C}$ -аас доош байхад модны дээд салаа хуваагдаж өндөр PM2.5 урьдчилан мэдэгддэг.

```
|--- temperature_2m <= -7.65
||--- wind_speed_10m <= 5.40
|||--- temperature_2m <= -18.35
|||--- ...
|||--- temperature_2m > -18.35
|||--- ...
||--- wind_speed_10m > 5.40
||--- ...
|--- temperature_2m > -7.65
|--- wind_speed_10m <= 8.10
||--- ...
||--- wind_speed_10m > 8.10
||--- ...
```

Эхний хуваалт температур  $-7.65^{\circ}\text{C}$ , хоёр дахь нь салхины хурдаар — салхи бохирдлыг тарааж шингэрүүлдэгийг илтгэнэ. Иймд:

- Халаалтын улирлын бохирдлыг бууруулах нь хамгийн их нөлөөтэй
- Салхигүй, хүйтэн өдрүүдэд иргэдийг анхааруулах систем боловсруулах боломжтой

## Д.9 Үр дүнгийн статистик тайлбар

Туршилтын өгөгдөл дээр хийсэн шинжилгээний дүгнэлт:

**R<sup>2</sup>:** Decision Tree-ийн  $R^2=0.535$  нь нийт хэлбэлзлийн 53.5%-ийг тайлбарлаж байна. Зөвхөн цаг агаарын хувьсагчаар тайлбарлагдах хэсгийг барьж байна.

**MAE:** Decision Tree хамгийн бага MAE-тай — дунджаар хамгийн бага алдаатай.  $\mu\text{g}/\text{m}^3$  нэгжтэй тул шууд физик утгаар тайлбарлагдана.

**RMSE:** RMSE нь MAE-ээс их = зарим таамаглалд том алдаа гарч байна. PM2.5 экстрим үед алдаа нэмэгддэг.

**Шугаман vs Шугаман бус:** LR ба BR бараг ижил ( $R^2=0.517$ ) — Байесын regularization нэмэлт давуу тал олгохгүй байна. DT  $R^2=0.535$  = температур-PM2.5-ийн шугаман бус хамаарлыг илрүүлж чадаж байна.

Иймээс загвар нь цаг агаарын хувьсагчаар PM2.5-ийг статистикийн хувьд утга учиртай түвшинд таамаглах чадвартай.

## Д.10 Загварын хязгаарлалт

Энэхүү загвар  $R^2=0.535$  гүйцэтгэлтэй. Хязгаарлалтууд:

**Нэгдүгээрт**, загвар цаг агаарыг мэдвэл PM2.5-ийг тооцдог — шууд урт хугацааны таамаглал гаргах

боломжгүй. Weather forecast оролт болговол 24–72 цагийн таамаглал боломжтой.

**Хоёрдугаарт**,  $R^2=0.535 = 46.5\%$  нь бусад хүчин зүйлээс хамаарна (замын хөдөлгөөн, үйлдвэр, гэр хороолол).

**Гуравдугаарт**, нэг цэгийн координат дээр суурилсан — хотын өөр хэсгүүдэд ялгаатай байж болно.

**Дөрөвдүгээрт**, цагийн нарийвчлалтай боловч микро-нөхцлүүдийг бүрэн барьж чадахгүй.

## Е. Ном Зүй

- [1] Zippenfenig, P. (2023). Open-Meteo.com weather API (Version 1) [Software]. Zenodo. <https://doi.org/10.5281/zenodo.7970649>
- [2] Open-Meteo. (2024). Air quality API: Historical air quality data [Dataset]. <https://open-meteo.com/en/docs/air-quality-api>
- [3] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. JMLR, 12, 2825–2830. [4] The pandas development team. (2024). pandas-dev/pandas: Pandas (Version 2.x). Zenodo. [5] Harris, C. R., et al. (2020). Array programming with NumPy. Nature, 585, 357–362.
- [6] Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. Computing in Science & Engineering, 9(3), 90–95.

## Ё. Python Код

Дараах код нь төслийн бүх алхмыг нэгтгэсэн бүрэн хувилбар юм.

```
# ===== # Улаанбаатар хотын агаарын бохирдлын таамаглал
# ===== import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression, BayesianRidge from sklearn.tree import
DecisionTreeRegressor, export_text
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score from sklearn.preprocessing
import StandardScaler
import warnings
warnings.filterwarnings('ignore')
# 1. OGOGDOL ACHAALAH
train_df = pd.read_csv('train.csv')
test_df = pd.read_csv('test.csv')
FEATURES = [
    'temperature_2m', 'relative_humidity_2m', 'wind_speed_10m', 'precipitation', 'surface_pressure',
    'month', 'hour', 'heating_season', 'temp_x_wind'
]
TARGET = 'pm2_5'
X_train = train_df[FEATURES]; y_train = train_df[TARGET]
X_test = test_df[FEATURES]; y_test = test_df[TARGET]
# 2. STANDARTCHLAL
scaler = StandardScaler()
X_train_sc = scaler.fit_transform(X_train)
X_test_sc = scaler.transform(X_test)
# 3. ZAGVARUUD SURGAH
lr = LinearRegression(); lr.fit(X_train_sc, y_train)
y_pred_lr = lr.predict(X_test_sc)
br = BayesianRidge(max_iter=500); br.fit(X_train_sc, y_train) y_pred_br = br.predict(X_test_sc)
dt = DecisionTreeRegressor(max_depth=6, min_samples_leaf=50, random_state=42) dt.fit(X_train, y_train);
y_pred_dt = dt.predict(X_test)
# 4. UNELGEE
def evaluate(name, y_true, y_pred):
    mae = mean_absolute_error(y_true, y_pred)
    rmse = np.sqrt(mean_squared_error(y_true, y_pred))
    r2 = r2_score(y_true, y_pred)
    print(f'[{name}] MAE={mae:.4f} RMSE={rmse:.4f} R2={r2:.4f}')
evaluate('Linear Regression', y_test, y_pred_lr)
evaluate('Bayesian Ridge', y_test, y_pred_br)
evaluate('Decision Tree', y_test, y_pred_dt)
```



```

# 5. GRAPH
fig, axes = plt.subplots(2, 3, figsize=(18, 10))
models = [('Linear Regression', y_pred_lr, 0.517),
          ('Bayesian Ridge', y_pred_br, 0.517),
          ('Decision Tree', y_pred_dt, 0.535)]
for ax, (nm, yp, r2) in zip(axes[0], models):
    ax.scatter(y_test, yp, alpha=0.3, s=5)
    ax.plot([0, y_test.max()], [0, y_test.max()], 'r--') ax.set_title(f'{nm}\nR2={r2}')
axes[1][0].bar(['LR', 'BR', 'DT'], [0.517, 0.517, 0.534]) axes[1][0].set_title('R2 haritstuulalt')
fi = pd.Series(dt.feature_importances_, index=FEATURES).sort_values() fi.plot(kind='barh', ax=axes[1][1])
axes[1][1].set_title('Feature Importance')
yp_br, ys = br.predict(X_test_sc, return_std=True)
idx = np.argsort(yp_br)
axes[1][2].fill_between(range(len(idx)),
                        (yp_br - 1.96 * ys)[idx], (yp_br + 1.96 * ys)[idx], alpha=0.3) axes[1][2].plot(yp_br[idx])
axes[1][2].set_title('Bayesian 95% CI')
plt.tight_layout(); plt.savefig('results.png', dpi=150)

```

### 3. Багийн гишүүдийн оролцоо

Энэхүү судалгааны ажлыг багийн гишүүд хамтын ажиллагааны үндсэн дээр гүйцэтгэв.

| Багийн гишүүн | Гүйцэтгэсэн ажил                                              |
|---------------|---------------------------------------------------------------|
| Д.Аахангай    | Тайлан, танилцуулга хийсэн                                    |
| Б.Өсөхбаяр    | Санааг гаргаж, датагаа бэлдэж хийгдэх ерөнхий загвар гаргасан |
| А.Баясгалан   | Python дээр модел сургасан                                    |

Багаараа цаг товлон уулзаж, зорилго болон сэдэв сонголтоо хийсэн. Хүн бүр өөрсдийн хийх ажлыг хуваан авч гэр гэрээсээ хийхээр болсон. GitHub дээр шинэ төсөл үүсгэж 3 гишүүд бүгд жигд оролцон хийсэн.

Багийн гишүүд судалгааны бүх үе шатанд харилцан санал солилцож, туршилтын үр дүнг хамтран шинжилж, тайланг эцэслэн боловсруулав.

