

Улаанбаатар хотын PM2.5 агаарын бохирдлын таамаглал

Цаг агаарын өгөгдлөөр PM2.5-ийг таамаглах машин сургалтын загвар

БАГИЙН ГИШҮҮД

Д. Аахангай · Б. Өсөхбаяр · А. Баясгалан

1. Судалгааны зорилго

Яагаад PM2.5-ийг цаг агаарын өгөгдлөөр таамаглах ёстой вэ?

Яагаад PM2.5 чухал вэ?

PM2.5 нь 2.5 микрометрээс бага диаметртэй тоосонцор бөгөөд хүний эрүүл мэндэд хамгийн их сөрөг нөлөөтэй бохирдуулагч юм.

Улаанбаатар ба өвлийн бохирдол

Түлш түлдэг үед гэр хорооллын зүүх, агаарын урвуу давхарга буюу температурын инверсийн үзэгдэл PM2.5-ийг ихсэхэд нөлөөлдөг.

СУДАЛГААНЫ АСУУЛТ

**"Цаг агаарын өгөгдлөөр
PM2.5-ийг таамаглаж
болох уу?"**

Хүлээгдэж буй үр өгөөж

Эрүүл мэндийн анхааруулга · Богино хугацааны таамаглал · Бодлого боловсруулагчдад нотолгоо

1. Судалгааны зорилго

Яагаад PM2.5-ийг цаг агаарын өгөгдлөөр таамаглах ёстой вэ?

Бидний амьдралд хэр их хэрэгцээтэй вэ?

“Таны хүүхэд гадаа тоглох гэж байна уу? Агаар цэвэр байна уу гэдгийг урьдчилан мэдэж болдог бол ямар вэ?

Манай машин сургалт яг тийм зүйл хийдэг — цаг агаарын мэдээллийг харж, маргааш агаар бохир байх уу? гэдгийг таамагладаг.”

Түвшин	Утга	Тайлбар
Цэвэр	0–15	ДЭМБ-ын 2021 оны зөвлөмж
Дунд зэрэг	15–25	MNS 4585 стандарт давах эхлэл
Эмзэг бүлэгт хортой	25–55	Хүүхэд, өндөр настанд эрсдэлтэй
Эрүүл мэндэд хортой	55–150	Бүх хүн амд сөрөг нөлөөтэй
Маш их бохирдолтой	150–250	Гадаа удаан байх нь зохисгүй
Аюултай	250+	Онцгой байдлын түвшин

СУДАЛГААНЫ АСУУЛТ

**"Цаг агаарын өгөгдлөөр
PM2.5-ийг таамаглаж
болох уу?"**

2. Өгөгдлийн эх сурвалж

Open-Meteo нээлттэй API · 2019–2024 · цагийн нарийвчлал

Open-Meteo Weather API

- температур (°C)
- салхины хурд (km/h)
- харьцангуй чийгшил (%)
- гадаргын даралт (hPa)
- хур тунадас (mm)

Open-Meteo Air Quality API

- PM2.5-ийн агууламж ($\mu\text{g}/\text{m}^3$)
- Зорилтот хувьсагч

БАЙРШИЛ

Улаанбаатар
47.92°N · 106.91°E

ХУГАЦАА

2019.01.01 –
2024.12.31

НАРИЙВЧЛАЛ

Цагийн өгөгдөл

3. Өгөгдөл нэгтгэх урсгал

Хоёр API-ийн өгөгдлийг огноо, цагийн баганын дагуу нэгтгэв



Цаг бүрийн цаг агаарын үзүүлэлт PM2.5-ийн утгатай нэг мөрөнд нэгтгэгдэнэ.

4. Өгөгдлийн цэвэрлэгээ

Алдаатай өгөгдлийн мөрүүдийг хасаж, сургалтын/шалгалтын өгөгдөл болгож хуваав

АНХНЫ ӨГӨГДӨЛ	ЦЭВЭРЛЭСНИЙ ДАРАА	УСТГАСАН	СУРГАЛТ / ШАЛГАЛТ
43,824	31,056	12,768 (29.1%)	24,844 / 6,212

ЦЭВЭРЛЭГЭЭНИЙ АЛХМУУД

- NaN утгатай мөрүүдийг устгасан
- Давхардсан огноо, цагийн утгуудыг устгасан
- PM2.5-ийн 0-ээс бага боломжгүй утгуудыг устгасан
- Сургалтын / шалгалтын өгөгдөл 80 / 20 харьцаатай хуваасан

43,824 мөрөөс 12,768 (29.1%) хасагдан 31,056 цэвэр мөр үлдсэн


5. Ашигласан оролтын шинжүүд

Цаг агаарын анхдагч хувьсагчид болон шинж үүсгэлт

Шинж	Нэгж	Тайлбар
temperature_2m	°C	Агаарын температур
wind_speed_10m	km/h	Салхины хурд (10 м өндөрт)
relative_humidity_2m	%	Харьцангуй чийгшил
precipitation	mm	Хур тунадасны хэмжээ
surface_pressure	hPa	Гадаргын даралт
month	1–12	Улирлын хэв маяг
hour	0–23	Өдрийн циклийн хэв маяг
heating_season	0 / 1	Түлш түлдэг үе (10–4 сар)
temp_x_wind	°C·km/h	Температур ба салхины харилцан үйлчлэл
pm2_5	µg/m³	Зорилтот хувьсагч

6. EDA · Корреляцийн шинжилгээ

PM2.5-тэй хамгийн хүчтэй хамааралтай хувьсагчид



ГОЛ ДҮГНЭЛТ

Температур буурах,
түлш түлдэг үе эхлэх,
салхи багасах үед
PM2.5 өсөх хандлагатай.

Сөрөг корреляц → урвуу хамаарал · Эерэг корреляц → шууд хамаарал

7. Ашигласан загваруудын тойм

Гурван өөр шинж чанартай регрессийн загвар

Linear Regression

ШУГАМАН ХАМААРАЛ

OLS аргаар хувьсагчдын хооронд шууд шугаман хамаарлыг тогтооно.

Bayesian Ridge

REGULARIZATION БА ТОДОРХОЙГҮЙ БАЙДАЛ

Gaussian prior ашиглан загварын коэффициентүүдийг тогтворжуулж, 95%-ийн итгэлцлийн интервалыг тооцоолдог.

Decision Tree

ШУГАМАН БУС ХАМААРАЛ

Хувьсагчдыг дараалан хуваан шугаман бус хамаарлыг барина.

8. Linear Regression

Шугаман регрессийн загвар

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n$$

- StandardScaler ашиглаж $\mu = 0$, $\sigma = 1$ болгов
- β коэффициент бүр оролтын шинжийн нөлөөг хэмждэг
- Хэрэгжүүлэхэд хялбар, тайлбарлахад тохиромжтой
- Сул тал: өндөр PM2.5 утгуудыг дутуу таамаглаж болно

R² SCORE

0.517

9. Bayesian Ridge Regression

Bayesian regularization-той шугаман загвар

$$P(\beta | X, y) \propto P(y | X, \beta) \cdot P(\beta)$$

- Bayesian regularization → хэт тохирлоос сэргийлдэг
- 95%-ийн итгэлцлийн интервал (CI) тооцоолох боломжтой
- `max_iter = 500` параметртэйгээр сургав
- Linear Regression-тэй маш төстэй гүйцэтгэлтэй

R² SCORE

0.517

10. Decision Tree Regressor

Шугаман бус хамаарлыг барих модны загвар

$$\text{MSE} = (1 / n) \cdot \sum (y_i - \bar{y})^2$$


- Шугаман бус хамаарлыг автоматаар олж барина
- `max_depth = 6` · `min_samples_leaf = 50`
- `feature_importances_` → оролтын шинжүүдийн чухлыг хэмждэг
- PM2.5-ийн 0-ээс бага утга таамаглахгүй

R² SCORE · ШИЛДЭГ

0.535

11. Загвар сургах ба үнэлэх алхам

Сургалт/шалгалт хуваалт → сургах → таамаглах → үнэлэх



Бүх загварыг ижил сургалт/шалгалт хуваалт дээр сургаж, ижил үнэлгээний үзүүлэлтүүдээр харьцуулав.

Код хэсэг

Шугаман регрессийн загвар

Хэрэгцээтэй сангуудаа татаж бэлдэх

```
python

import pandas as pd          # Өгөгдөл унших, хүснэгт
import numpy as np           # Тооцоолол
import matplotlib.pyplot as plt # График зурах

from sklearn.linear_model import LinearRegression, BayesianRidge
from sklearn.tree import DecisionTreeRegressor
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
from sklearn.preprocessing import StandardScaler
```

Код хэсэг

Шугаман регрессийн загвар

Өгөгдөл ачааллах

```
python
```

```
train_df = pd.read_csv("train.csv") # Сургалтын дата  
test_df  = pd.read_csv("test.csv")  # Туршилтын дата
```

Код хэсэг

Шугаман регрессийн загвар

Х, У ялгах

Тайлбар: "Х бол асуулт, у бол хариулт. Загвар Х харж у таамагладаг."

```
python
```

```
FEATURES = ['temperature_2m', 'relative_humidity_2m', 'wind_speed_10m',  
            'precipitation', 'surface_pressure',  
            'month', 'hour', 'heating_season', 'temp_x_wind']  
TARGET = 'pm2_5'
```

```
X_train = train_df[FEATURES] # Оролт (9 багана)  
y_train = train_df[TARGET]   # Гаралт (PM2.5)  
X_test  = test_df[FEATURES]  
y_test  = test_df[TARGET]
```


Код хэсэг

Шугаман регрессийн загвар

Стандарчлал

Тайлбар: "Температур -40 байж, хурд 10 байна. Тоонуудын хэмжээ өөр өөр учраас загвар эргэлздэг. Стандартчлал бол бүх тоог адил хэмжигдэхүүн болгох — жишээ нь сургуулийн оноо шиг 0-100 болгоно."

```
scaler = StandardScaler()  
X_train_sc = scaler.fit_transform(X_train)  
X_test_sc = scaler.transform(X_test)
```

Загвар №1 : Linear Regression

Санаа: PM2.5 ба хувьсагчдын хооронд шулуун шугам олно.

"Хэрэв температур нэгдэхэд PM2.5 5.2 нэмэгдэнэ гэдгийг олно. Шулуун шугам шиг — энгийн боловч үргэлж зөв биш."

```
lr = LinearRegression()  
lr.fit(X_train_sc, y_train)  
y_pred_lr = lr.predict(X_test_sc)
```

Томъёо ийм харагдана:

$$\text{PM2.5} = (5.2 \times \text{температур}) + (-3.1 \times \text{салхи}) + (8.4 \times \text{халаалт}) + \dots$$

Загвар №2 : Байесын Регресс

Санаа: Linear Regression-тай төстэй, гэхдээ нэмэлт онцлогтой — "яг хэр итгэлтэй байна?" гэж хэлэх чадвартай.

```
br = BayesianRidge(max_iter=500)
br.fit(X_train_sc, y_train)
y_pred_br_mean, y_pred_br_std = br.predict(X_test_sc, return_std=True)
```

95% CI (итгэлийн интервал) гэж юу? - 95% итгэлтэйгээр PM2.5 утга
35-47 хооронд байна гэж хэлж байна.

```
Таамаглал: 41.2  $\mu\text{g}/\text{m}^3$ 
95% CI: [35.0, 47.4]
```

Код хэсэг

Загвар №3 : Decision Tree

Санаа: Олон шийдвэр дараалан гаргаж хариулалтад хүрнэ.

```
dt = DecisionTreeRegressor(max_depth=6, min_samples_leaf=50, random_state=42)
dt.fit(X_train, y_train)    # ← Стандартчлал шаардахгүй!
y_pred_dt = dt.predict(X_test)
```

```
PS C:\Users\User\Documents\magadlal\Ub_air_quality> python air_quality_model.py
```

```
heating_season    0.000000
```

```
--- Шийдвэрийн модны дүрэм (depth=3 хүртэл) ---
```

```
|--- temperature_2m <= -7.65
```

```
| |--- wind_speed_10m <= 4.55
```

```
| | |--- wind_speed_10m <= 1.75
```

```
| | | |--- surface_pressure <= 870.75
```

```
| | | |--- truncated branch of depth 3
```

```
| | | |--- surface_pressure > 870.75
```

```
| | | |--- truncated branch of depth 3
```

```
| | |--- wind_speed_10m > 1.75
```

```
| | | |--- surface_pressure <= 868.65
```

```
| | | |--- truncated branch of depth 3
```

```
| | | |--- surface_pressure > 868.65
```

```
| | | |--- truncated branch of depth 3
```

```
| | |--- wind_speed_10m > 4.55
```

Код хэсэг

Загваруудыг үнэлэх

MAE — Дундаж Абсолют Алдаа

MAE = 10 гэвэл Таамаглал дунджаар $10 \mu\text{g}/\text{m}^3$ алдна.

Тайлбар: Хэрэв бодит PM2.5 = 40, таамаглал = 30 бол алдаа = 10. MAE бол алдаануудын дундаж.

RMSE = Томоохон алдааг илүү шийтгэдэг

Тайлбар: Ихэнхдээ ойрхон боловч заримдаа маш их алдаа гаргавал RMSE өндөр болно.

R^2 — Тайлбарлах Чадвар

$R^2 = 1.0 \rightarrow$ Төгс (100% зөв)

$R^2 = 0.7 \rightarrow$ 70% зөв тайлбарладаг

$R^2 = 0.0 \rightarrow$ Юу ч тайлбарлахгүй

12. Загваруудын гүйцэтгэл


Decision Tree R^2 хамгийн өндөр гарав

Загвар	MAE	RMSE	R^2
Linear Regression	~8-10	~11-13	0,517
Bayesian Ridge	~8-10	~11-13	0,517
Decision Tree	Хамгийн бага	Хамгийн бага	0,535

Decision Tree бүх үнэлгээний үзүүлэлтээр хамгийн сайн үр дүн үзүүлсэн — шугаман бус хамаарлыг илрүүлж байна

13. Таамагласан ба бодит утга — Linear Regression

Таамагласан ба бодит утгын тархалтын график



R^2 SCORE


0.517

ТАЙЛБАР

- Бага PM2.5-ийг боломжийн таамагласан
- Өндөр утгуудыг ($60+ \mu\text{g}/\text{m}^3$) дутуу таамагласан
- Зарим тохиолдолд PM2.5-ийн 0-ээс бага утга таамагласан

14. Таамагласан ба бодит утга — Bayesian Ridge

Таамагласан ба бодит утгын тархалтын график



R^2 SCORE


0.517

ТАЙЛБАР

- LR-тэй маш төстэй тархалт
- Regularization нэмэлт давуу тал өгөөгүй
- Давуу тал: 95%-ийн итгэлцлийн интервал тооцоолдог (cf. слайд 19)

15. Таамагласан ба бодит утга — Decision Tree

Таамагласан ба бодит утгын тархалтын график



R^2 SCORE


0.535

ТАЙЛБАР

- Шугаман бус хамаарлыг илүү сайн барьсан
- Хэвтээ зурвас — төгсгөлийн зангилаа бүрт тогтмол утга
- PM2.5-ийн 0-ээс бага утга таамаглахгүй

16. R^2 харьцуулалт

Гурван загварын тайлбарлах чадварыг харьцуулав



дүгнэлт


Decision Tree PM2.5-ийн өөрчлөлтийн

53.5%-ийг

цаг агаарын өгөгдлөөр тайлбарласан.

17. Шинжийн чухал зэрэглэл

Decision Tree-ийн хувьд хамгийн чухал хувьсагчид



ХАМГИЙН ЧУХАЛ 3 ШИНЖ

temperature_2m

53.4 %

wind_speed_10m

18.9 %


temp_x_wind

11.2 %

Температур хамгийн чухал хүчин зүйл болсон

18. Bayesian Ridge — 95%-ийн итгэлцлийн интервал

Тодорхойгүй байдлыг тоон утгаар илэрхийлсэн загвар



АЖИГЛАЛТ

- 95%-ийн итгэлцлийн интервал ихэнх утгыг хамарсан
- Хэт өндөр PM2.5 үед зарим утга интервалаас гарсан
- Бодлого боловсруулагчдад тодорхойгүй байдлыг үнэлэх боломж
- Цэгэн таамаглалд итгэлцлийн интервал нэмэлт мэдээлэл өгдөг

19. Загварын хязгаарлалт

Цаашид сайжруулах боломжтой чиглэлүүд

Зөвхөн цаг агаарын өгөгдөл

Бусад хүчин зүйлс ороогүй

Замын хөдөлгөөн, ялгаруулалт, дүүргийн түвшний өгөгдөл ороогүй

PM2.5-д шууд нөлөөлдөг

Улаанбаатар хотыг төлөөлөх нэг координат дээр суурилсан

Улаанбаатар хотыг төлөөлөх координат 47.92°N, 106.91°E

Урт хугацааны шууд таамаглал биш

Цаг агаарын урьдчилсан мэдээ хэрэгтэй

Цаг агаарын урьдчилсан мэдээ ашиглавал 24–72 цагийн PM2.5 таамаглал хийх боломжтой

20. Дүгнэлт

Судалгааны үндсэн үр дүн

- **Decision Tree хамгийн сайн загвар: $R^2 = 0.535$**
- Температур хамгийн чухал хүчин зүйл: 53.4 %
- Салхины хурд хоёр дахь чухал хүчин зүйл: 18.9 %
- Цаг агаарын өгөгдлөөр PM2.5-ийг дунд түвшний нарийвчлалтай таамаглаж чадсан
- Нэмэлт өгөгдөл (замын хөдөлгөөн, ялгаруулалт) оруулбал загвар сайжрах боломжтой

Энэ судалгаа нь цаг агаарын урьдчилсан мэдээг ашиглан агаарын чанарын богино хугацааны анхааруулга хийх боломжтойг харуулж байна.

БАГИЙН ОРОЛЦОО

Баярлалаа

Д. Аахангай

Тайлан болон танилцуулга бэлтгэх

Б. Өсөхбаяр

Өгөгдөл бэлтгэх, ерөнхий загвар

А. Баясгалан

Python дээр загвар сургах

Асуулт байна уу?

PM2.5 таамаглал · Магадлал Статистикийн Төсөл · 2026